

Alcanzando los objetivos de desarrollo sostenible

En 2015, la ONU adoptó la Agenda 2030 para el desarrollo sostenible, definiendo 17 Objetivos de Desarrollo Sostenible (ODS) orientados a reducir la pobreza, mejorar el acceso a salud y educación, promover la igualdad y disminuir el impacto ambiental. Diversas entidades, como el UNFPA, participan en el seguimiento y evaluación de políticas públicas relacionadas con estos objetivos, apoyándose en información proveniente de procesos de participación ciudadana.

No obstante, el análisis de grandes volúmenes de información textual representa un desafío por su complejidad y alto consumo de recursos. En este contexto, el proyecto propone desarrollar una solución basada en procesamiento de lenguaje natural y machine learning que permita clasificar automáticamente los textos según los ODS, facilitando la toma de decisiones y el diseño de políticas públicas más informadas.

A. Objetivo.

- Desarrollar una solución, basada en técnicas de procesamiento de lenguaje natural y machine learning, que facilite la interpretación y análisis de información textual para la identificación de relaciones semánticas con los Objetivos de Desarrollo Sostenibles.

B. Conjunto de datos.

El conjunto de datos forma parte del proyecto “OSDG Community Dataset”¹ (OSDG-CD), en su versión 2023, que contiene un total de 40.067 textos, de los cuales 3000 provienen de fuentes relacionadas con las Naciones Unidas. También contiene documentos públicos, resúmenes de artículos y reportes. La plataforma reúne investigadores, expertos en la materia y defensores de los ODS de todo el mundo para crear una fuente amplia y precisa de información textual sobre los ODS. Los voluntarios de la comunidad utilizan la plataforma para participar en ejercicios de etiquetado en los que validan la relevancia de cada texto para los ODS basándose en sus conocimientos previos.

Los textos que serán utilizados en este proyecto han sido traducidos al español por herramientas como DeepL². También se realizó una aumentación de textos a través del API de ChatGPT³.

C. Actividades para realizar.

1. Preparación de los textos utilizando al menos dos esquemas de ponderación basados en matrices dispersas.

¹ OSDG Community Dataset (OSDG-CD). (<https://osdg.ai/news/New-release-of-OSDG-Community-dataset>).

² <https://www.deepl.com/es/translator>

³ <https://chat.openai.com/g/g-l1XNbsyDK-api-docs>

2. Desarrollo de dos pipelines de clasificación que integren un modelo de Naïve Bayes con cada uno de los esquemas definidos en el punto anterior, con el fin de asociar textos a los ODS.
3. Realizar una tabla comparativa que muestre las métricas de rendimiento sobre test, con base en los dos esquemas de pesado.
4. Evaluación del mejor modelo empleando textos que no hayan sido utilizados durante el proceso de entrenamiento.

D. Entregable.

Notebook (*.ipynb y *.html) del método desarrollado. El Notebook debe estar documentado con las justificaciones de las decisiones tomadas en cada paso. Además, deben ser visibles las ejecuciones de cada celda. Para evidenciar el desempeño del método construido el notebook debe mostrar las clasificaciones para al menos cuatro textos del conjunto test.

F. Criterios de evaluación.

Actividad	Porcentaje
Preparación de los textos, justificando las decisiones tomadas.	35%
Construcción de los dos pipelines de preparación de textos, con la inclusión del modelo clasificación con el algoritmo Naïve Bayes, validándolo con medidas de evaluación adecuadas.	45%
Elaboración de la tabla comparativa.	10%
Evidencia del desempeño del método, con base en el mejor modelo, mostrando las clasificaciones sobre un conjunto de textos que no hayan sido utilizados durante el aprendizaje	10%